

AI – TECH

SKRYPT DO LABORATORIUM

UCZENIE MASZYNOWE

LABORATORIUM 3:

Algorytmy klasyfikacji nienadzorowanej

Adam Kurowski



**Rzeczpospolita
Polska**

Unia Europejska
Europejski Fundusz
Rozwoju Regionalnego



1. Zagadnienia wstępne

1.1.Wymagania w odniesieniu do studenta

W ramach przygotowania do zajęć, student powinien powtórzyć lub zapoznać się z podstawowymi zagadnieniami związanymi z klasyfikacją nadzorowaną, redukcją wymiarowości i ogólną wiedzą dotyczącą programowania. Przed przystąpieniem do wykonania ćwiczenia zaleca się:

- powtórzenie wiedzy nabytej w czasie wykładów,
- zapoznanie się (przed ćwiczeniem) z instrukcją do ćwiczenia ilustrującą podstawowe zagadnienia z zakresu tematyki ćwiczenia.

Ponadto wymagana jest od studenta:

- podstawowa umiejętność programowania,
- podstawowa znajomość języka Python,
- podstawowa znajomość algorytmów uczenia maszynowego przedstawionych w trakcie trwania wykładów
- umiejętność rozwiązywania problemów.

Wyżej wymienione wymagania bazują na wiedzy i umiejętności jakie studenci powinni zdobyć w czasie edukacji na I poziomie studiów oraz w trakcie trwania 1 semestru studiów II stopnia. W przeciwnym przypadku studenci powinni nadrobić samodzielnie stosowny materiał.

1.2.Wymagania w odniesieniu do stanowiska laboratoryjnego

Stanowisko laboratoryjne powinno być wyposażone w komputer z dostępem do sieci komputerowej oraz z następującymi zasobami:

- przykładowe programy (kody programów) podane w załączniku
- zainstalowany język Python w wersji przynajmniej 3.6.5
- Jupyter Notebook
- biblioteki niezbędne do realizacji ćwiczenia
- przeglądarka WWW.

Wykaz bibliotek języka Python wraz z numerami wersji i odnośnikami URL do ich dokumentacji w formie on-line zamieszczony jest poniżej:

Nazwa biblioteki	Wersja	Odkładnik do dokumentacji
Matplotlib	1.18.1	https://matplotlib.org/
MLxtend	1.1.5	http://rasbt.github.io/mlxtend/
NumPy	3.0.3	https://numpy.org/doc/stable/reference/
Pandas	0.24.1	https://pandas.pydata.org/
Pillow (PIL)	0.18.0	https://pillow.readthedocs.io/en/stable/
SciPy	1.5.4	https://docs.scipy.org/doc/scipy/reference/
Scikit-learn	6.1.0	https://scikit-learn.org/stable/

Przed przystąpieniem do wykonywania ćwiczenia warto zapoznać się z ogólnymi opisami narzędzi dostępnymi we wspomnianych bibliotekach, gdyż często znajduje się tam wiele gotowych, przydatnych i co najważniejsze – szeroko używanych, przetestowanych narzędzi realizujących różne skomplikowane zadania. Pozwala to na uniknięcie implementowania od początku algorytmów, które już wcześniej zostały przez kogoś zaprogramowane w dobry, szeroko zweryfikowany przez użytkowników biblioteki sposób.

Istnieje możliwość realizacji ćwiczenia w zewnętrznym środowisku [Google Colaboratory](https://colab.research.google.com/) na platformie Google, gdzie wymagane jest od użytkownika posiadanie konta Google, natomiast nie ma potrzeby konfiguracji środowiska.

Na komputerze powinna znajdować się instrukcja do ćwiczenia w wersji elektronicznej oraz pozostałe pliki niezbędne do wykonania ćwiczenia. Przed zajęciami należy sprawdzić czy dostępne są na stanowisku wymagane zasoby i programy. Szczególnie w zakresie potrzebnych bibliotek języka Python.

1.3.Cele ćwiczenia

Celem ćwiczenia jest praktyczna demonstracja wiedzy teoretycznej, przedstawionej w ramach wykładów. Realizując ćwiczenie laboratoryjne studenci zdobędą szereg nowych umiejętności w zakresie poprawnego doboru i używania algorytmów klasyfikacji nienadzorowanej w zadaniach związanych z analizą danych i przetwarzaniem informacji o złożonej strukturze. W laboratorium posłużono się przykładem segmentacji pisma i przetwarzaniem kolorowych obrazów w formacie RGB. Studenci w ramach zajęć nabędą wiedzę dotyczącą między innymi następujących zadań:

- wizualizacji danych o wysokiej wymiarowości (zarówno z, jak i bez wykorzystania redukcji wymiarowości) w celu szybkiego szacowania stopnia uporządkowania i skupienia danych w odseparowane od siebie skupiska (klastry),
- analizy danych, dla których nie istnieją etykiety dzielące je na klasy,
- analizy wpływu normalizacji danych na zachowanie się algorytmów klasyfikacji nienadzorowanej,
- właściwego doboru rodzaju algorytmu i jego hiperparametrów w kontekście zadania, jakie ten algorytm ma realizować (np. analiza danych bez etykiet, przetwarzanie multimediów, itd.),
- umiejętności określenia, które problemy mogą wymagać wykorzystania technik klasyfikacji nienadzorowanej, w celu ich rozwiązania.

1.4. Spodziewane efekty kształcenia - umiejętności i kompetencje:

Student po zajęciach laboratoryjnych będzie posiadał umiejętność przygotowania danych oraz zastosowania technik klasyfikacji nienadzorowanej, w celu poznania struktury danych, analizy skupień i zaawansowanego przetwarzania danych multimedialnych. Będzie także potrafił dobierać odpowiednie algorytmy do rodzaju danych, jaki ma być przeanalizowany i posiadać umiejętność doboru hiperparametrów w celu maksymalizacji efektywności wykonywanych działań.

1.5. Metody dydaktyczne

Zadanie rozpocznie się od konfiguracji środowiska programistycznego, którym może być zarówno środowisko on-line takie jak usługa Google Colaboratory, jak i lokalnie uruchamiane oprogramowanie Jupyter. Dalsze działania odbywać się będą na podstawie dodatkowych materiałów i demonstracji prowadzącego, studenci będą wykonywać zadania przygotowane w postaci interaktywnych dokumentów Jupytera. Konieczne jest zarówno przyswojenie treści przekazywanych przez prowadzącego, jak i znajomość wstępnych, podstawowych zagadnień niezbędnych do zrozumienia omawianych tematów. Na początku przedstawiane są proste problemy i demonstracje, kolejne zadania są coraz bardziej skomplikowane, przedstawiają coraz bardziej zaawansowane pojęcia, oraz wymagają bardziej intensywnego i kreatywnego zaangażowania ze strony wykonującego ćwiczenie studenta.

Wszystkie kody źródłowe programów wpisuje w dokumencie elektronicznym (lub pokazuje prowadzącemu), który jednocześnie staje się sprawozdaniem z ćwiczenia laboratoryjnego.

1.5. Zasady oceniania

Ocenie podlegać będzie realizacja poszczególnych zadań w ramach danego ćwiczenia laboratoryjnego. W trakcie realizacji ćwiczenia możliwe jest przydzielenie przez prowadzącego dodatkowych zadań oraz zadawanie pytań dotyczących ćwiczenia. Premiowane są także wszelkie próby wyciągnięcia i uogólnienia wniosków wypływających z wykonywanych ćwiczeń. Mogą one dotyczyć zarówno aspektów teoretycznych, jak i praktycznych wykonywanych analiz.

Poszczególnym zadaniom przydzielono liczbę punktów jakie można zdobyć za ich wykonania. Maksymalna liczba punktów wynosi 10.

Wykaz literatury podstawowej do ćwiczenia:

Wykaz literatury podstawowej:

1.	Skrypt z materiałami do przedmiotu „Uczenie Maszynowe”
2.	Materiały do przedmiotu opracowane w formie edukacji na odległość, dostęp: https://enauczenie.pg.edu.pl/moodle/course/view.php?id=12525
3.	Aurélien Géron, Uczenie maszynowe z użyciem Scikit-Learn i TensorFlow. Wydanie II, Helion 2020
4.	Sebastian Raschka, Python. Uczenie maszynowe, Helion 2017
5.	Alberto Boschetti, Luca Massaron, Python. Podstawy nauki o danych. Wydanie II, Helion 2017
6.	Jiawei Han, Micheline Kamber, Jian Pei, Data Mining: Concepts and Techniques, Morgan Kaufmann Series in Data Management Systems 2012
7.	Jerome H. Friedman, Robert Tibshirani i Trevor Hastie, The Elements of Statistical Learning, 2 nd ed., Springer 2017

Wykaz literatury uzupełniającej:

1.	Dokumentacja bibliotek wymienionych w sekcji dotyczącej wymagań względem stanowiska
2.	Dokumentacja platformy Colaboratory: https://colab.research.google.com/notebooks/intro.ipynb#scrollTo=-gE-Ez1qtyIA
3.	Francois Chollet, Deep Learning. Praca z językiem Python i biblioteką Keras, Helion 2019

2. Przebieg ćwiczenia

L.p.	Zadanie
1.	Zapoznanie się z instrukcją laboratoryjną (przed ćwiczeniem)
2.	Wprowadzenie kierownika ćwiczenia. Zapoznanie się uczestników ze stosowanymi programami, przegląd dokumentacji (10 min.)
3.	Klasyfikacja nadzorowana i nienadzorowana bazująca na metrykach odległości (20 min.);
4.	Dobór liczby klas w algorytmie k średnich i klasteryzacji hierarchicznej (30 min.);
5.	Porównanie jakości segmentacji tekstu za pomocą algorytmu k średnich, hierarchicznego i bazującego na gęstości punktów (DBSCAN) (35 min.);
6.	Wykorzystanie algorytmu k średnich do segmentacji obrazów (35 min.);
7.	Przesłanie/pokazanie zbioru dokumentów/programów do oceny (5 min.).

UWAGI!

PRZED przystąpieniem do ćwiczenia należy utworzyć własny, unikalny katalog w lokalizacji wskazanej przez prowadzącego, a następnie należy tam umieścić pliki testowe oraz własne implementacje kodu programów dokonujących rozwiązania zadanie. Należy pracować wyłącznie na wykonanej kopii plików.

3. Wprowadzenie do ćwiczenia

Klasyfikacja w uczeniu maszynowym typowo kojarzy się z danymi opisującymi obiekty należące do różnych klas. Mogą to być na przykład samochody wyprodukowane przez różne marki producentów, zdjęcia przedstawiające różnego rodzaju przedmioty codziennego użytku, czy też różne grupy osób o zbieżnych preferencjach zakupowych. Typowo dostępny jest zbiór danych opisujący za pomocą szeregu parametrów obiekty do niego należące. W zbiorze tym dostępna jest także informacja o tym, do jakiej klasy należy obiekt opisywany przez wybrany obiekt. Często sytuację tę można przedstawić w formie tabelarycznej tak jak w tab. 1. Zwykle każdy wiersz z takiej tabeli określa się mianem *punktu danych* (ang. *data point*). Robi się tak dlatego, że każdy z punktów np. z tab. 1

może być rozważany jak kartezjańskie współrzędne punktu, która dla zbioru Iris jest czterowymiarowa.


Tabela 1. Przykładowe dane pochodzące ze zbioru Iris, w którym dostępne są cztery cechy opisujące wymiary kielicha kwiatowego (sepal_length, sepal_width) i płatków irysów (petal_length, petal_width), należących do trzech różnych gatunków (kolumna species). Klasą w przypadku tego zbioru danych jest właśnie gatunek irysa.

sepal_length	sepal_width	petal_length	petal_width	species
5,1	3,5	1,4	0,2	setosa
4,9	3	1,4	0,2	setosa
4,7	3,2	1,3	0,2	setosa
6	3,4	4,5	1,6	versicolor
5,8	2,6	4	1,2	versicolor
5	2,3	3,3	1	versicolor
6,3	3,3	6	2,5	virginica
5,8	2,7	5,1	1,9	virginica
7,1	3	5,9	2,1	virginica

Logika analizowania danych tak jak zbiory punktów nabiera jeszcze bardziej na znaczeniu w przypadku, gdy powiadamy dane, jednak nie mamy do dyspozycji kolumny, która dzieli je na klasy (tak jak robi to np. kolumna species w przypadku zbioru Iris). Możemy wtedy polegać jedynie na geometrycznym układzie punktów w przestrzeni (lub w ogólności – w hiperprzestrzeni, jak nazywamy przestrzenie o n wymiarach – w domyśle n może przybierać względnie duże wartości). Podstawowym środkiem do odróżnienia od siebie klas danych jest analiza odległości pomiędzy punktami, a także analiza gęstości ich występowania w różnych rejonach hiperprzestrzeni. Podejście to bywa także stosowane w klasyfikacji nadzorowanej – podstawowym przykładem takiego klasyfikatora jest algorytm k najbliższych sąsiadów. W przypadku zbiorów danych w których nie posiadamy etykiet – zmuszeni jesteśmy posługiwać głównie takim odległościowym podejściem do wyróżniania skupisk danych (nazywanych także czasami klastrami od angielskiej nazwy *clusters*). Jest to tak zwana

klasyfikacja nienadzorowana. Zadanie odszukiwania skupisk punktów w bywa także nazywane *analizą skupień* (ang. *cluster analysis*).


Przykładowo, aby zilustrować sobie, do czego posłużyć może klasyfikacja nienadzorowana rozważmy sobie zbiór danych, w którym zgromadzona jest informacja o osobach robiących zakupy w sklepie. Posiadamy informacje jedynie na temat wysokości głosu osób tam przebywających i na temat ich wzrostu. Chcemy dowiedzieć się, jaka jest struktura płci osób robiących zakupy. Są to dwie współrzędne, które łatwo możemy przeanalizować poprzez naniesienie ich na wykres punktowy, co widać na rys. 1.



Rysunek 1. Wykresy punktowe – jednowymiarowy (oś liczbowa, po lewej) i dwuwymiarowy (po prawej), które ujawniają informacje na temat osób robiących zakupy w hipotetycznym sklepie.

Rys. 1 ujawnia informację o tym, że wysokości głosu osób znajdujących się w sklepie sugerują, że dane skupione są w dwa klastry, uwiadczenia się to nawet przy wizualizacji danych na osi liczbowej. Po dodaniu do analizy kolejnego wymiaru – wzrostu ta tendencja wzmacnia się. Stąd możemy przypuszczać, że prawdopodobnie w sklepie przebywają dwie, mniej więcej równoliczne grupy osób.

Najprawdopodobniej zatem zakupy w wybranym miejscu lubią robić zarówno mężczyźni, jak i kobiety (zakładamy, że we wspomnianym hipotetycznym sklepie zakupów nie robią dzieci), co może być interesującą informacją np. dla osób opracowujących kampanie marketingowe dla badanego sklepu. Analiza taka może być rozszerzana o dodatkowe wymiary, co powoduje skomplikowanie wizualizacji służących do wyciągania tego typu wniosków. O ile wizualizacja w 3 wymiarach jest jeszcze intuicyjna, tak problem pojawia się w przypadku 4 wymiarów i więcej. Przykładem rozwiązania takiego problemu jest np. wykres współrzędnych równoległych, który razem z wizualizacją trójwymiarową pokazany jest na rys. 2.



Rysunek 2. Przykład wykresu dla trójwymiarowej przestrzeni (po lewej) oraz przykład wykresu we współrzędnych równoległych (po prawej). Dla czytelności w wykresie współrzędnych równoległych ograniczono liczbę punktów danych do trzech. Każda osoba ze zbioru przypisana jest do jednej niebieskiej łamanej na wykresie.

Jak jest to widoczne na rys. 2, zobrazowanie za pomocą współrzędnych równoległych pozwala do pewnego stopnia zobrazować zależności pomiędzy punktami danych (i np. określić, czy występują wartości odstające) nawet w wysokowymiarowych zbiorach danych.

W przykładach pokazanych na rys. 1 i 2 grupy danych można wyróżnić wizualnie. W praktycznym przypadku zadanie to wymaga zwykle wykorzystania specjalnego algorytmu przeprowadzającego proces klasyfikacji nienadzorowanej. W ramach niniejszego laboratorium przedstawione będą trzy algorytmy tego typu:

1. **algorytm k średnich**, który analizuje zakłada występowanie k skupisk w analizowanych danych i iteracyjnie dobiera współrzędne ich punktów centralnych tak, aby oddzielić od siebie poszczególne skupiska.
2. **algorytm hierarchiczny**, który łączy pojedyncze punkty oraz mniejsze grupy punktów w większe skupiska tak, aby wybrana metryka (np. średnia odległość punktów każdej klasy od środka związanego z nimi skupiska) była możliwie niska,
3. **algorytm DBSCAN**, który oddziela skupiska od siebie na podstawie analizy gęstości rozmieszczenia punktów w różnych miejscach badanej hiperprzestrzeni.

Praktyczne zastosowania algorytmów klasyfikacji nienadzorowanej są nieco mniej intuicyjne i oczywiste niż zastosowania klasyfikacji nadzorowanej. Nienadzorowane algorytmy klasyfikacji przydają się we wszystkich sytuacjach, w których konieczne jest podzielenie danych na grupy, które istotnie się od siebie odróżniają np. poprzez skupienie ich w różnych obszarach hiperprzestrzeni. Stąd przykładami praktycznego zastosowania algorytmów klasyfikacji nienadzorowanej są między innymi:

- zliczanie mówców słyszalnych na nagraniu dźwiękowym (każdy mówca to osobna klasa ramek mowy),
- określanie grup konsumentów o podobnych preferencjach zakupowych (interesuje nas ile klas występuje, jak bardzo są liczne, oraz np. jakie produkty najchętniej kupują),
- analiza zapisu biosygnatów (np. EEG) w celu odszukania wyróżniających się fragmentów rejestracji mogących np. świadczyć o postępującym procesie chorobowym,

- ograniczanie liczby kolorów w obrazach (każda klasa odpowiada jednemu możliwemu kolorowi) – na przykład w celu późniejszego poddania tak przetworzonego kompresji, lub by osiągnąć efekt artystyczny.

Szczegółowe opisy algorytmów oraz poszczególne fragmenty kodów niezbędnych do wykonania ćwiczenia zostały umieszczone w skryptach Jupyter notebook, które są nierozłącznym elementem instrukcji do tego ćwiczenia laboratoryjnego (lista plików w dodatku).

4. Forma i zawartość sprawozdania

Ocenie podlegać będzie realizacja poszczególnych zadań w ramach danego ćwiczenia laboratoryjnego. Szczególnie premiowane będą dodatkowe wnioski i obserwacje poczynione samodzielnie przez osoby wykonujące ćwiczenie. Zarówno te dotyczące różnego rodzaju teoretycznych aspektów wykonywanych czynności, jak i ich możliwych praktycznych zastosowań. Poszczególnym zadaniom przydzielono liczbę punktów jakie można zdobyć za ich wykonania. Maksymalna liczba punktów wynosi 10.

Dodatki:

Pliki instruktażowe oraz pliki z danymi, niezbędne do wykonania ćwiczenia laboratoryjnego:

- 1) *LAB3_P1.ipynb*
- 2) *LAB3_P2.ipynb*
- 3) *LAB3_P3.ipynb*
- 4) *LAB3_P4.ipynb*
- 5) *kwiat.jpg*
- 6) *logo.jpg*
- 7) *wzor_matematyczny.png*